

# DLNLP 第二次作业

ZY2103202 黄君辉

## 一. 任务描述

一个袋子中三种硬币的混合比例为： $s_1, s_2$ 与  $1 - s_1 - s_2 (0 \leq s_i \leq 1)$ ，三种硬币掷出正面的概率分别为： $p, q, r$ 。（1）自己指定系数 $s_1, s_2, p, q, r$ ，生成 $N$ 个投掷硬币的结果（由01构成的序列，其中1为正面，0为反面），利用 EM 算法来对参数进行估计并与预先假定的参数进行比较。

## 二. 方法介绍

### 2.1 模型介绍——三硬币模型

假设有 3 枚硬币，分别记作  $A$ ， $B$  和  $C$ 。这些硬币正面向上的概率分别是  $\pi$ ， $p$  和  $q$ 。进行如下抛硬币试验：

- 1、先抛硬币 A，根据其结果选出硬币 B 或者硬币 C，正面选硬币 B，反面选硬币 C；
- 2、然后掷选出的硬币，抛硬币的结果，出现正面记作 1，出现反面记作 0；
- 3、独立重复  $n$  次试验 (这里  $n = 10$ )，观测结果如下：

1, 1, 0, 1, 0, 0, 1, 0, 1, 1

假设只能观测到掷硬币的结果，不能观测掷硬币的过程。问如何估计三硬币正面出现的概率，即三硬币模型参数。对于单次观测结果，三硬币模型可以写作：

$$\begin{aligned} p(y_j|\theta) &= \sum_z p(y_j, z|\theta) \\ &= \sum_z p(z|\theta)p(y_j|z, \theta) \\ &= \pi p^{y_j}(1-p)^{1-y_j} + (1-\pi)q^{y_j}(1-q)^{1-y_j} \end{aligned}$$

其中  $y_j$  是第  $j$  个观测结果 1 或 0；随机变量  $z$  是隐变量，表示未观测到的掷硬币 A 的结果；

$\theta = (\pi, p, q)$  是模型参数。方便起见，观测数据可以表示为  $y = (y_1, y_2, \dots, y_n)^T$ ，隐变量数据可以表示为  $z = (z_1, z_2, \dots, z_n)^T$ 。观测数据的似然函数可以表示为：

$$\begin{aligned} p(y|\theta) &= \sum_z p(y|z, \theta) \\ &= \prod_{j=1}^n [\pi p^{y_j}(1-p)^{1-y_j} + (1-\pi)q^{y_j}(1-q)^{1-y_j}] \end{aligned}$$

## 2.2 算法推导——EM 算法

最大期望算法（Expectation-maximization algorithm，又译为期望最大化算法），是在概率模型中寻找参数最大似然估计或者最大后验估计的算法，其中概率模型依赖于无法观测的隐性变量。为方便上述问题求解，对上式取对数似然函数，即

$$L(\theta) = \log p(y|\theta) = \log\left(\sum_z (p(y|z, \theta)p(z|\theta))\right)$$

其中  $L(\theta) < 0$ 。运用迭代的思想解决这个问题，假设在第  $i$  次迭代后  $\theta$  的估计值是  $\theta^i$ 。想要求取最大对数似然，就需要  $L(\theta) > L(\theta^i)$ ，并逐步达到极大值，也就是它们的差值达到最大值：

$$J(\theta) = L(\theta) - L(\theta^i) = \log\left(\sum_z (p(y|z, \theta)p(z|\theta) - \log p(y|\theta^i))\right)$$

利用 Jensen 不等式，可以得到其下界。设

$$Q(\theta, \theta^i) = \sum_z (p(z|y, \theta^i) \log p(y, z|\theta))$$

则求取的是

$$\theta^{i+1} = \arg \max_{\theta} Q(\theta, \theta^i),$$

可以得到 EM 算法的步骤如下：

1. E 步：求隐变量  $p(z|y, \theta^i)$ ：给定观测数据  $y$  和当前的参数估计  $\theta^i$ ，求取隐变量  $z$  的条件概率分布；
2. M 步：将隐变量当做已知量，求  $Q(\theta, \theta^i)$  的极大化  $\theta$ ；
3. 重复执行 E 步和 M 步直到收敛

进一步，设  $y_j$  来自掷硬币 B 的概率为  $\mu_j$ ，则来自 C 的概率为  $1 - \mu_j$ ，且  $\mu_j \in \{0, 1\}$ ， $j = 1, 2, \dots, n$ ，参数  $\mu$  也为模型的隐变量。代入 EM 算法求解得到：

$$\begin{aligned}\pi^{i+1} &= \frac{1}{n} \sum_{j=1}^n \mu_j^i \\ p^{i+1} &= \frac{\sum_{j=1}^n \mu_j^i y_j}{\sum_{j=1}^n \mu_j^i} \\ q^{i+1} &= \frac{\sum_{j=1}^n (1 - \mu_j^i) y_j}{\sum_{j=1}^n (1 - \mu_j^i)}\end{aligned}$$

## 2.3 公式推导

对于本次作业中三种不同硬币，设定模型参数为 $\theta = (s_1, s_2, p, q, r)$ ,硬币定义为 $z_1, z_2, z_3$ ，每次观测结果表示为 $x = (x_1, x_2, \dots, x_n)^T$ ,则对于任一次观测 $x_i$ ,其概率模型为

$$\begin{aligned} p(x_i|\theta) &= \sum_z (p(x_i, z|\theta)) \\ &= \sum_z p(z|\theta)p(x_i|z, \theta) \\ &= s_1 p(x_i|z_1, \theta) + s_2 p(x_i|z_2, \theta) + (1 - s_1 - s_2) p(x_i|z_3, \theta) \end{aligned}$$

其中已知硬币产生观测结果的概率为：

$$\begin{aligned} p(x_i|z_1, \theta) &= x_i p + (1 - x_i)(1 - p) \\ p(x_i|z_2, \theta) &= x_i q + (1 - x_i)(1 - q) \\ p(x_i|z_3, \theta) &= x_i r + (1 - x_i)(1 - r) \end{aligned}$$

设 $x_i$ 来自掷硬币 A 的概率为 $\mu_1$ ,来自掷硬币 B 的概率为 $\mu_2$ ,则来自 C 的概率为 $\mu_3 = 1 - \mu_1 - \mu_2$ ，则有：

$$\begin{aligned} \mu_1(x_i) &= \frac{s_1 p(x_i|z_1, \theta)}{p(x_i|\theta)} \\ \mu_2(x_i) &= \frac{s_2 p(x_i|z_2, \theta)}{p(x_i|\theta)} \\ \mu_3(x_i) &= \frac{s_3 p(x_i|z_3, \theta)}{p(x_i|\theta)} \end{aligned}$$

将观测结果加权求和即可得到该序列来自于哪个硬币的估计值，即硬币分布的估计值：

$$\begin{aligned} s_1 &= \frac{1}{n} \sum_{i=1}^n \mu_1(x_i) \\ s_2 &= \frac{1}{n} \sum_{i=1}^n \mu_2(x_i) \end{aligned}$$

利用上面提到的 EM 算法进行迭代求解：

$$p^{t+1} = \frac{\sum_{i=1}^n \mu_1(x_i, \theta^t) x_i}{\sum_{i=1}^n \mu_1(x_i, \theta^t)}$$

$$q^{t+1} = \frac{\sum_{i=1}^n \mu_2(x_i, \theta^t) x_i}{\sum_{i=1}^n \mu_2(x_i, \theta^t)}$$

$$r^{t+1} = \frac{\sum_{i=1}^n \mu_3(x_i, \theta^t) x_i}{\sum_{i=1}^n \mu_3(x_i, \theta^t)}$$

重复上述步骤直到收敛，即可得到模型参数  $\theta = (s_1, s_2, p, q, r)$  的估计值

## 三. 实验

### 3.1 实验设计

本次实验中需要自行指定相关参数，因此 EM 算法求解的结果存在多种可能，实验设计考虑如下几种典型情况：

1. 模型参数固定，取出次数固定，但每次投掷次数改变
2. 模型参数固定，投掷次数固定，但取出次数变化
3. 取出次数固定，投掷次数固定，但模型真实参数变化
4. 取出次数固定，投掷次数固定，但算法迭代初始参数变化

每次实验均设定误差为  $e = \|\theta^{t+1}\| - \|\theta^t\| \leq 10^{-5}$ ，即相邻两次迭代估计的参数向量模长之差小于  $10^{-5}$  时停止迭代，得到最终的参数估计结果。

具体实验代码见附录及 <https://github.com/Jinhan-Lin/DL-NPL2>

### 3.2 实验结果

#### 1. 模型参数固定，取出次数固定，但每次投掷次数改变

此次实验中指定模型真实参数为  $\theta_t = (0.4, 0.3, 0.5, 0.6, 0.8)$ ，指定初始迭代参数为  $\theta^0 = (0.5, 0.3, 0.3, 0.4, 0.5)$ ，取出次数  $N = 1000$ ，投掷次数分别为  $M = 100, 10, 1$ ，实验结果如下：

指定模型参数		$\theta_t = (0.4, 0.3, 0.5, 0.6, 0.8)$
初始迭代参数		$\theta^0 = (0.5, 0.3, 0.3, 0.4, 0.5)$
取出次数		$N = 1000$
投掷次数	迭代轮数	最终求解结果
$M = 100$	73	$\theta = (0.3941, 0.3050, 0.5033, 0.5982, 0.8011)$
$M = 10$	376	$\theta = (0.2239, 0.5939, 0.4600, 0.6210, 0.8590)$
$M = 1$	6	$\theta = (0.4898, 0.3096, 0.5499, 0.6484, 0.7424)$

可以看出，投掷次数对于迭代轮数和求解结果存在较大影响，当投掷次数过小时，EM 算法容易求得局部最优解，无法收敛到真实结果。当  $M = 100$  时，求解速度较快，并且准确率可以达到较高水平。

## 2. 模型参数固定，投掷次数固定，但取出次数变化

此次实验中指定指定模型真实参数为  $\theta_t = (0.4, 0.3, 0.5, 0.6, 0.8)$ ，指定初始迭代参数为  $\theta^0 = (0.5, 0.3, 0.3, 0.4, 0.5)$ ，投掷次数为  $M = 100$ ，但取出次数分别为  $N = 1000, 500, 100$ ，实验结果如下：

指定模型参数		$\theta_t = (0.4, 0.3, 0.5, 0.6, 0.8)$
初始迭代参数		$\theta^0 = (0.5, 0.3, 0.3, 0.4, 0.5)$
投掷次数		$M = 100$
取出次数	迭代轮数	最终求解结果
$N = 1000$	73	$\theta = (0.3941, 0.3050, 0.5033, 0.5982, 0.8011)$
$N = 500$	43	$\theta = (0.3953, 0.3038, 0.4953, 0.6020, 0.8025)$
$N = 100$	46	$\theta = (0.2122, 0.4747, 0.4631, 0.5642, 0.7975)$

可以看出，取出次数对于迭代轮数影响较小，但对求解结果存在较大影响。投掷次数过少是，EM 算法很难求得精确的结果；但投掷次数也并非越多越好，当  $N = 500$  时，求解精度与  $N = 1000$  时相差无几，但计算量少了很多。

## 3. 取出次数固定，投掷次数固定，但模型真实参数变化

此次实验中指定指定初始迭代参数为  $\theta^0 = (0.5, 0.3, 0.3, 0.4, 0.5)$ ，投掷次数为  $M = 100$ ，取出次数为  $N = 500$ ，指定真实参数为： $\theta_t = (0.4, 0.3, 0.5, 0.6, 0.8)$ 、

$\theta_t = (0.2, 0.3, 0.5, 0.6, 0.8)$ 、 $\theta_t = (0.4, 0.3, 0.5, 0.5, 0.5)$  实验结果如下:

初始迭代参数	$\theta^0 = (0.5, 0.3, 0.3, 0.4, 0.5)$
取出次数	$N = 500$
投掷次数	$M = 100$
模型真实参数	最终求解结果
$\theta_t = (0.4, 0.3, 0.5, 0.6, 0.8)$	$\theta = (0.3953, 0.3038, 0.4953, 0.6020, 0.8025)$
$\theta_t = (0.2, 0.3, 0.5, 0.6, 0.8)$	$\theta = (0.2377, 0.2722, 0.5034, 0.6072, 0.7993)$
$\theta_t = (0.4, 0.3, 0.5, 0.5, 0.5)$	$\theta = (0.5274, 0.2720, 0.5112, 0.4780, 0.4998)$

在三种硬币投掷实验中, 如果 A,B,C 中任意两者的分布概率和正面概率不同, EM 算法就能很好地求出模型的相关参数。但是如第三个实验所示, B 种和 C 种硬币分布概率均为 0.3, 正面概率也均为 0.5, 此时可以认为 B,C 为同一类, 因此 EM 算法无法求解得到两种硬币准确的参数。

#### 4. 取出次数固定, 投掷次数固定, 但迭代参数变化

此次实验中指定指定初始迭代参数为 $\theta_t = (0.4, 0.3, 0.5, 0.6, 0.8)$ , 投掷次数为 $M = 100$ , 取出次数为 $N = 500$ , 指定真实参数为: $\theta^0 = (0.5, 0.3, 0.3, 0.4, 0.5)$ 、 $\theta^0 = (0.3, 0.3, 0.5, 0.6, 0.8)$ 、 $\theta^0 = (0.3, 0.3, 0.5, 0.5, 0.5)$  实验结果如下:

真实模型参数	$\theta_t = (0.4, 0.3, 0.5, 0.6, 0.8)$
取出次数	$N = 500$
投掷次数	$M = 100$
初始迭代参数	最终求解结果
$\theta^0 = (0.5, 0.3, 0.3, 0.4, 0.5)$	$\theta = (0.3953, 0.3038, 0.4953, 0.6020, 0.8025)$
$\theta^0 = (0.2, 0.5, 0.3, 0.4, 0.5)$	$\theta = (0.4470, 0.2555, 0.5054, 0.6062, 0.8032)$
$\theta^0 = (0.3, 0.3, 0.5, 0.6, 0.8)$	$\theta = (0.3737, 0.3263, 0.4972, 0.5964, 0.7988)$
$\theta^0 = (0.3, 0.3, 0.5, 0.5, 0.5)$	$\theta = (0.3, 0.3, 0.6207, 0.6207, 0.6208)$

可以看出, 初始迭代参数对 EM 算法求解结果的影响更大, 如果初始迭代参数离真实参数距离过远, 求解结果需要经过多轮迭代才能接近真实模型参数, 甚至无法准确得到最终结果; 此外, 和第 3 类情况类似, 如果初始迭代参数中三种硬币存在相同的分布和正面概率, 最终求

解结果也无法正确收敛，每次都在第二次迭代时就会判定为收敛。

## 四. 总结

总的来说，传统 EM 算法对初始值敏感，收敛的优劣很大程度上取决于其初始参数，最终结果随不同的初始值而波动较大。EM 算法可以保证收敛到一个稳定点，但是却不能保证收敛到全局的极大值点，因此它是局部最优的算法。